

Analiza Odejść Klientów w Branży Fitness

Analiza czasu trwania sem. letni 2025/2026

Szkola Główna Handlowa w Warszawie


29 czerwca 2026

Cel projektu i charakterystyka danych



- **Problem biznesowy:** Identyfikacja czynników determinujących rezygnację klientów z członkostwa w sieci fitness.
- **Próba badawcza:** 5000 obserwacji, w tym 1908 odnotowanych zdarzeń (odejść).
- **Dlaczego analiza przeżycia?** Tradycyjna regresja logistyczna bada jedynie fakt wystąpienia zdarzenia. Modele przeżycia badają czas do jego wystąpienia, uwzględniając obserwacje cenzurowane.

Estymator Kaplana-Meiera

- Krzywe przeżycia wyznaczone dla grup wyodrębnionych ze względu na płeć.
- Wizualna ocena wskazuje na niemal całkowite nakładanie się krzywych dla kobiet i mężczyzn.
- Największa intensywność odejść występuje w początkowych miesiącach trwania umowy.



Diagnostyka kształtu funkcji hazardu



- **Wyglądzony hazard (lewy):** Ryzyko nie jest stałe - początkowo rośnie, a następnie maleje dla lojalnych klientów.
- **Wykres LLS (prawy):** Brak przebiegu w postaci linii prostej wyklucza zastosowanie rozkładu Weibulla czy wykładniczego.

Weryfikacja zmiennych i wnioski wstępne

Weryfikacja istotności zmiennych kategoriycznych przed budową modelu:

Wyniki testów wielozmiennych (Log-Rank)

- **Płeć (gender):** $p - value = 0,1913$
- **Typ kontraktu (membership_type):** $p - value = 0,7169$

Wniosek i pomost do modelowania semiparametrycznego:

- Cechy demograficzne oraz wstępny typ umowy są **nieistotne statystycznie** ($p > 0,05$).
- Nieliniowy kształt hazardu wymusza rezygnację z modeli parametrycznych.
- Powyższe obserwacje uzasadniają budowę modelu proporcjonalnych hazardów Coxa, aby zbadać wpływ zachowań klientów (np. logowań, zajęć) na ryzyko odejścia.

Założenia Modelu Semiparametrycznego Coxa

- **Postać modelu:**

$$h_i(t) = \lambda_0(t) \exp(\beta_1 x_{i1} + \dots + \beta_k x_{ik})$$

gdzie $\lambda_0(t)$ to nieparametryczny, elastyczny hazard bazowy, a komponent wykładniczy reprezentuje część parametryczną.

- **Założenie proporcjonalności:** Stosunek hazardu dla dwóch jednostek jest stały w czasie i zależy wyłącznie od wartości zmiennych objaśniających:

$$\frac{h_i(t)}{h_j(t)} = \exp(\beta(X_i - X_j)) = \text{const.}$$

- **Specyfika czasu dyskretnego:**

- Zmienna czasu `subscription_length` przyjmuje wartości całkowite (miesięczne), co formalnie sprowadza model do struktury proporcjonalnych szans (Proportional Odds):

$$\log\left(\frac{P_{it}}{1 - P_{it}}\right) = \alpha_t + \beta_1 x_{i1} + \dots + \beta_k x_{ik}$$

- Założenie proporcjonalności oznacza tutaj, że stosunek szans (*odds ratio*) dla dwóch klientów pozostaje niezależny od upływu czasu.

Tabela: Wyniki estymacji modelu bazowego Coxa

Zmienna	coef (β)	exp(coef)	se(coef)	p-value
age	-0,000	1,000	0,002	0,934
female	-0,060	0,941	0,046	0,189
num_logins	-0,015	0,985	0,002	<0,001 *
num_complaints	0,083	1,087	0,017	<0,001 *
num_classes_attended	-0,040	0,961	0,004	<0,001 *
avg_session_time	0,001	1,001	0,001	0,353
membership_type	0,001	1,001	0,006	0,821

Partial AIC: 29094

Wstępny model proporcjonalnych hazardów Coxa ujawnił kluczowe predyktory behawioralne:

Interpretacja współczynników

- **Skargi** (`num_complaints`): Każda kolejna skarga podnosi ryzyko natychmiastowego odejścia klienta o **8,7%** ($HR = 1,087$).
- **Zajęcia fitness** (`num_classes_attended`): Każde wyjście na zajęcia zmniejsza ryzyko odejścia o **3,9%** ($HR = 0,961$).
- **Logowania** (`num_logins`): Każde logowanie do aplikacji zmniejsza ryzyko o **1,5%** ($HR = 0,985$).

Zmienne demograficzne (wiek, płeć) oraz okazały się **statystycznie nieistotne** ($p > 0,05$).

Tabela: Wyniki testu reszt Schoenfelda

Zmienna	Statystyka testowa	p-value
num_classes_attended	7,66	0,01
num_complaints	4,58	0,03
num_logins	4,73	0,03

- Test reszt Schoenfelda jednoznacznie **odrzuć hipotezę zerową** dla istotnych zmiennych ($p < 0,05$).
- **Wniosek:** Wpływ zachowań klientów na ryzyko odejścia zmienia się w czasie i nie jest stały.

Tabela: Wyniki estymacji dynamicznego modelu Coxa

Zmienna	coef (β)	exp(coef)	se(coef)	p-value
age	0,005	1,005	0,003	0,085
avg_session_time	0,001	1,001	0,001	0,363
female	-0,056	0,945	0,046	0,219
num_classes_attended	-0,023	0,977	0,007	0,002 *
num_complaints	0,036	1,037	0,030	0,226
num_logins	-0,011	0,989	0,003	<0,001 *
time * age	-0,000	1,000	0,000	0,033 *
time * num_classes	-0,001	0,999	0,000	0,007 *
time * num_logins	-0,000	1,000	0,000	0,086
time * num_complaints	0,002	1,002	0,001	0,059



Partial AIC: 23082

- **Efekt zmiennych zależnych od czasu:** Wprowadzenie interakcji pokazało, że siła wpływu zachowań klientów nie jest stała i rośnie z każdym miesiącem.
- **Spadek AIC:** Przejście z modelu tradycyjnego do specyfikacji dynamicznej ze stratyfikacją wyraźnie zmniejszyło AIC z 29094 do 23082.
- **Wniosek:** Model dynamiczny jest lepszą formą specyfikacji modelu. Model statyczny upraszcza rzeczywistość i zaniża długookresowe znaczenie aktywności klientów.

Dobór modelu parametrycznego

Przesłanki za wyborem rozkładu Weibulla:

- 1 Krzywa K-M jest malejąca i wklęsła – kandydatem na model parametryczny jest model Weibulla z parametrem $\sigma < 1$ – model przyspieszonej porażki z rosnącą funkcją hazardu
- 2 Wykres log-log przebiega w przybliżeniu liniowo – warunek konieczny dla modelu Weibulla



Porównanie AIC

Model	AIC
Weibull	20080,74
Log-logistyczny	20304,83
Log-normalny	20502,73

Model przyspieszonej porażki (AFT) to model parametryczny, w którym zmienna zależna to logarytm czasu trwania:

$$\log T_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \sigma \varepsilon_i$$

Parametry szacowane są przez MNW:

$$L = \prod_{i: \text{zdarzenie}} f(t_i) \cdot \prod_{i: \text{ocenzurowane}} S(t_i)$$

Parametr kształtu $1/\sigma$

- $1/\sigma < 1$ hazard **malejący** w czasie
- $1/\sigma = 1$ hazard **stały** (model wykładniczy)
- $1/\sigma > 1$ hazard **rosnący** w czasie

Interpretacja współczynników: $\exp(\beta_k)$ to iloraz czasu – jednostkowy wzrost x_k mnoży oczekiwany czas trwania przez $\exp(\beta_k)$.

Tabela: Estymacja modelu Weibulla AFT


Zmienna	coef	exp(coef)	se(coef)	p-value
num_classes_attended	0,028	1,029	0,003	<0,001 *
num_complaints	-0,064	0,938	0,012	<0,001 *
num_logins	0,011	1,011	0,001	<0,001 *
age	-0,000	1,000	0,001	0,779
avg_session_time	-0,001	0,999	0,001	0,287
gender_Male	-0,042	0,959	0,034	0,212
membership_type	–	–	–	>0,05
rho_ (skala)	0,309	1,362	0,020	<0,001

AIC = 20080,74 Concordance = 0,59 $\hat{\sigma} = e^{-0,31} = 0,73$, $1/\hat{\sigma} = 1,37 > 1$

Weryfikacja i interpretacja modelu Weibulla AFT

Weryfikacja graficzna:

- Krzywa przeżycia z modelu Weibulla pokrywa się z krzywą K-M na przedziale (0, 57)
- Rozbieżności po miesiącu 57 wynikają z małej liczby obserwacji w tym przedziale



Interpretacja istotnych zmiennych

- **num_classes_attended:** każde zajęcie wydłużają członkostwo o **2,9%**
- **num_logins:** każde logowanie wydłuża członkostwo o **1,1%**
- **num_complaints:** każda skarga skraca członkostwo o **6,2%**

Wniosek: Efekt skargi jest ok. 2-krotnie silniejszy niż zajęć i 6-krotnie silniejszy niż logowania. Mała liczba dobrych zajęć jest cenniejsza niż duża liczba kiepskich.

Dziękujemy za uwagę!